

**Zadanie nr 3 - implementacja i  
zastosowanie sieci RBF**  
Inteligentna Analiza Danych

Robert Makrocki, 224368      Wojciech Piątkowski, 224399

03.06.2020

# 1 Cel zadania

Wykorzystanie sieci RBF do aproksymacji i klasyfikacji na danych z poprzednich zadań.

## 2 Wstęp teoretyczny

Neuronowa sieć RBF z dwoma warstwami: warstwą radialną z neuronami z gaussowską funkcją radialną i warstwą neuronów z identycznościową funkcją aktywacji.

Wzór na radialną funkcję bazową [2]:

$$\varphi_i(x) = \varphi(\|x - c_i\|) \quad (1)$$

gdzie:  $x$  - wektor,  $c_i$  - centrum.

Wzór na funkcję celu [2]:

$$E = \sum_{i=1}^p \left[ \sum_{j=1}^K w_j \varphi(\|x_i - c_j\|) - d_i \right]^2 \quad (2)$$

gdzie:  $p$  - ilość wzorców treningowych.

Funkcja Gaussa [2]:

$$\varphi(x_i) = \exp\left(-\frac{\|x - c_i\|^2}{2\sigma_i^2}\right) \quad (3)$$

## 3 Eksperymenty i wyniki

### 3.1 Osobna nauka warstw, aproksymacja funkcji

Eksperyment polegał na wykorzystaniu sieci RBF do aproksymacji funkcji. Do nauki wykorzystano dane z plików:

- `approximation_train_1.txt`,
- `approximation_train_2.txt`.

Natomiast w celu sprawdzenia jakości aproksymacji użyto dane z pliku `approximation_test.txt`.

### 3.1.1 Założenia

- Warstwy trenowane osobno.
- Dla warstwy radialnej, wektory centrów dobierane poprzez losowy wybór wektorów ze zbioru treningowego.
- Współczynniki skalujące dobierane z uwzględnieniem odległości między centrami i wpływu poszczególnych funkcji gaussowskich.
- Wagi neuronów warstwy liniowej dobierane są tak jak wagi warstwy wyjściowej sieci MLP za pomocą metody wstecznej propagacji błędów [1].

Domyślne wartości parametrów:

- Ilość neuronów w warstwie radialnej = 20.
- Maksymalna liczba sąsiadów = 5.
- Ilość epok = 20.

### 3.1.2 Przebieg

- Losujemy wektory centrów warstwy radialnej za pomocą wektorów ze zbioru treningowego.
- Liczymy ilość sąsiadów i sortujemy ich względem odległości.
- Rozpoczynamy naukę sieci.
- Punkty treningowe są przemieszane po każdej epoce.
- Wsteczna propagacja.
- Liczymy błąd średniokwadratowy.
- Co epokę efekty nauki przenosimy na wykresy i zapisujemy do katalogów.


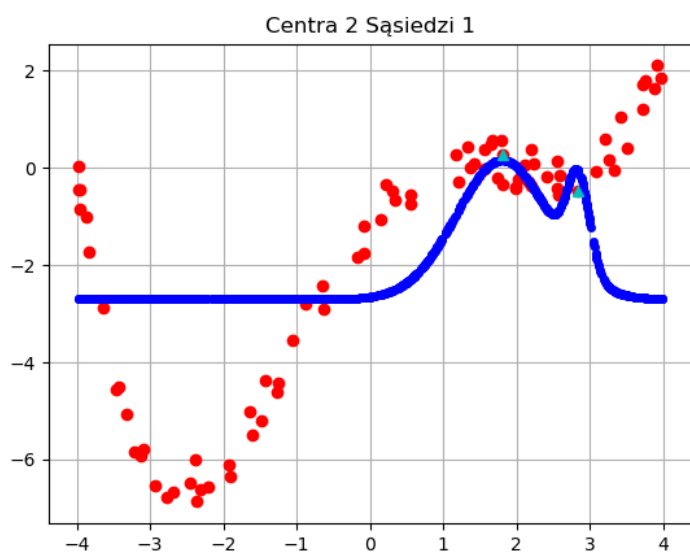
### 3.1.3 Rezultat




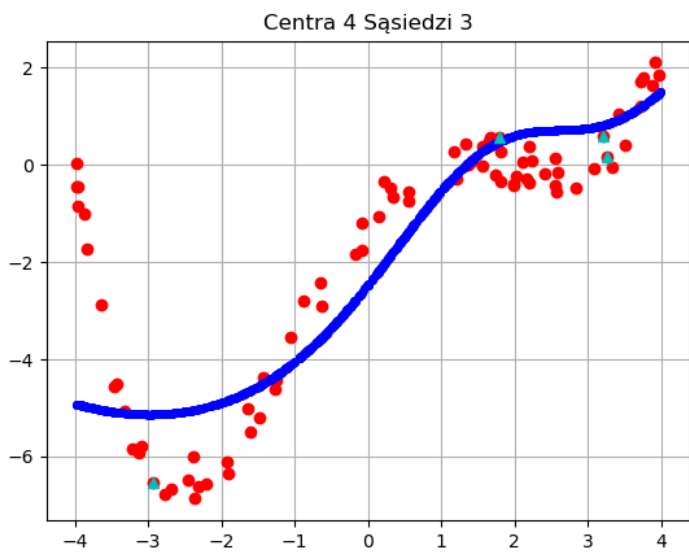
Rezultaty nauki sieci RBF dla domyślnych wartości parametrów.





Wykresy są tworzone w odniesieniu do odpowiedniej ilości centr i sąsiadów.



Lewy wykres obrazuje funkcję aproksymacji na układzie współrzędnych, a prawy wykres błąd średniokwadratowy.

Rezultaty treningu na danych z pliku `approximation_train_1.txt`:










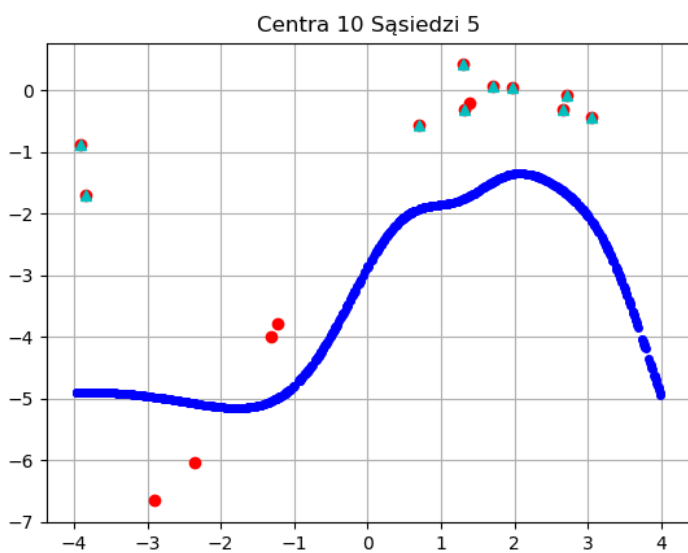

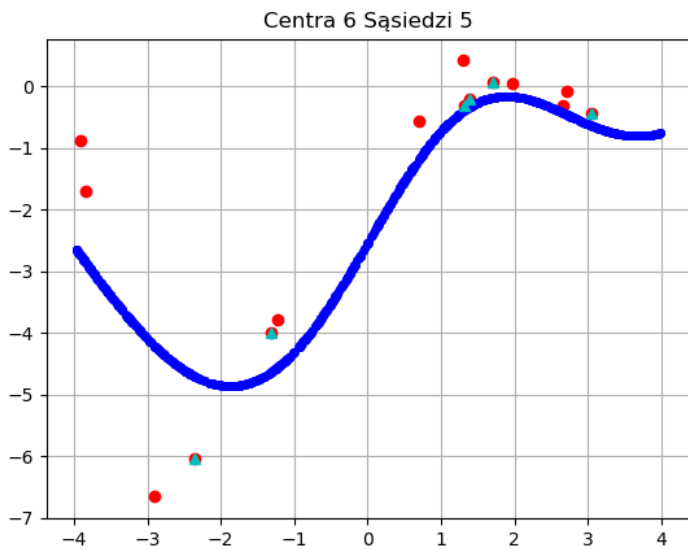








Rezultaty treningu na danych z pliku approximation\_train\_2.txt:









## 4 Wnioski

- Znaczący wpływ na efekt nauki mają wylosowane centra.
- Większa ilość centr poprawia jakość aproksymacji (nie większa od ilości punktów ze zbioru danych).

## Bibliografia

- [1] *Wzory związane z perceptronem wielowarstwowym.*
- [2] Bartłomiej Stasiak. *Inteligentna analiza danych - Modele neuronów i sieci neuronowych Algorytmy adaptacji*, 2012.